

IMPROVEMENT STUDY

AlphaEarth Embedding 可解释性复现

改进方案与性能提升分析报告

Extremely Randomized Trees as a Lightweight Upgrade to the Random Forest Module

项目	内容
基线	chabingcha/alphaearth-reproduction 的 64-D embedding → 26 环境变量 RF 复现
改进组件	论文 2.4.2 Random Forest regression 模块
主实验	20 个独立数据种子 × 26 个目标变量；严格配对随机留出评估
扩展验证	空间分块留出、五模型消融、4 组鲁棒性压力测试、支持集恢复
AI 辅助	方案推理、代码生成、测试、统计分析、可视化与报告编制
日期	2026-07-29

实测结果；不含虚构或外推到真实 AlphaEarth 数据的性能数字

摘要

本研究基于 AlphaEarth embedding 可解释性基线复现，针对论文中“为每个环境变量训练独立随机森林”的组件提出轻量改进：使用 Extremely Randomized Trees (ExtraTrees)，通过随机化切分阈值降低树间相关性，并以 70% 特征子采样和 100 棵树控制方差。为避免原复现单次随机种子与 OOB 评分带来的证据不足，本研究将性能声明限定在严格外部留出集，并在 20 个独立合成数据种子上进行配对实验。

主结果显示，随机留出宏平均 R^2 从 0.4909 提升至 0.5158，平均配对增益为 +0.0249，95% bootstrap 置信区间 [0.0223, 0.0275]；配对 t 检验 $p=2.06e-13$ ，Wilcoxon $p=1.91e-06$ ，20/20 个种子全部获益。空间分块留出同样从 0.4406 提升至 0.4685 ($\Delta R^2=+0.0279$)。

完整 ExtraTrees 的中位拟合与评估时间为 2.71s，基线为 3.19s，机器实测约快 15%。支持集 mAP 从 0.8827 增至 0.8901，但未达到显著性；Mapping Recall@3 保持 0.9625。因此结论是：该改进显著提高合成复现任务的预测精度和效率，且未观察到可解释性恢复退化；尚不能据此声称真实 12.1M AlphaEarth 样本上同等提升。

核心结论 ExtraTrees 是一个经配对统计支持的 RF 轻量替换：随机留出 +0.0249 R^2 ，空间留出 +0.0279 R^2 ，20/20 种子获益，同时保持 Top-3 映射召回。

1. 研究背景与改进入口

1.1 原论文与复现基线

Rahman (2026) 使用 12.1M 个 CONUS 多年样本，将 64 维 AlphaEarth embeddings 与 26 个环境变量对应起来。论文使用 Spearman 相关、随机森林和多任务 Transformer 三种互补方法；其中 RF 以全部 64 维为输入，为每个环境变量分别建模，并通过 5 折交叉验证与置换重要性形成 64×26 重要性矩阵。论文报告 12/26 个变量 $R^2>0.90$ ，Transformer 对全部 26 个变量优于 RF。

课程基线复现由于真实 AlphaEarth 数据访问与算力限制，采用具有已知映射的合成数据、2,000 个样本、30–50 棵 RF 树与 OOB 评分。该设计成功验证了方法流程，但单次数据种子、OOB 指标与容易达到上限的 Top-3 恢复率不足以支撑“改进有效”的统计结论。

1.2 识别出的限制与优化空间

表 1 基线复现的关键限制及本研究响应

限制	证据/风险	本研究处理
单次种子	结果可能依赖一次随机映射和噪声实现	20 个独立数据种子，所有比较严格配对
OOB 与训练流程耦合	不等价于统一外部测试集；模型间不一定公平	同一 75/25 留出切分作为主终点
RF 树间相关	bootstrap + 最优阈值可能在小样本下放大分裂方差	随机切分阈值的 ExtraTrees
Top-1 指标上限	多个真维度映射到同一变量时逐映射 Top-1 理论上不可达 100%	报告 support mAP、Recall@true-k、Recall@3
随机空间切分乐观	相邻样本共享空间结构	独立 4° 空间块 GroupShuffleSplit
合成数据外部效度	缺少真实光谱、时间和传感器噪声结构	结论仅限合成复现，并明确未来真实数据验证

2. 改进假设与技术方案

2.1 可证伪假设

- H1（主假设）** 在相同合成数据种子和相同外部测试划分下，100 棵 ExtraTrees + max_features=0.7 的宏平均测试 R^2 高于 50 棵标准 Random Forest。
- H2（空间稳健性）** 改进在未见空间块上仍保持正的配对 ΔR^2 ，而不是仅在随机留出中受益。
- H3（可解释性非劣化）** 维度支持集恢复指标不出现系统性下降；特别是 Mapping Recall@3 不低于基线。

2.2 为什么选择 ExtraTrees

标准 RF 在每个候选特征上搜索较优切分点，再通过 bootstrap 聚合树。ExtraTrees 进一步随机化候选切分阈值，用更高的单树随机性换取更低的树间相关性；大量树平均后可降低集成方差。Geurts 等（2006）将计算效率和偏差—方差分析列为该方法的核心性质。这一改动不改变输入/输出接口：仍是 64 维 embedding 到单个连续环境变量的树集成回归，因此能直接替换论文 RF 组件，也保留特征重要性。

完整方案设 100 棵树、max_features=0.7、min_samples_leaf=1、无 bootstrap。树数增加用于稳定随机阈值带来的方差；70% 特征曝光进一步去相关。消融实验分别隔离“随机阈值”“增加树数”“特征子采样”与完整组合。

3. AI 辅助实现与代码鲁棒性

AI 编码工具协助完成了改进假设细化、指标上限审计、模块化代码生成、统计方法实现、可视化与报告编制。所有模型结果均由本机脚本实际运行生成；AI 未手工填写任何 R^2 或 p 值。

表 2 修改代码与鲁棒性措施

文件	修改内容	清晰标记/保障
data/generate_synthetic_data.py	新增 per-call random_seed，消除运行顺序依赖	IMPROVEMENT MODIFICATION START/END
src/improved_extra_trees.py	模型工厂、外部留出评估、支持集指标	AI-ASSISTED IMPROVEMENT 文件头
experiments/run_improvement_experiment.py	主实验、空间验证、消融、鲁棒性、统计、图表	配置写入 JSON；原始行级 CSV 可审计
tests/test_improvement.py	模型类型、完美排名、GT 反转测试	3/3 pytest 通过
results/improvement/	CSV、JSON 和 6 张实测图	可由单命令完整重建

输入检查覆盖 X/Y 形状、变量名数量、训练/测试集合非空与互斥、ground truth 索引范围；模型随机种子按 dataset seed 与 target index 派生。统计输出同时记录 Python、NumPy、SciPy、scikit-learn、平台和 CPU 数量。

4. 实验设计

表 3 预先规定的比较实验设计

维度	设置
主数据	每个种子 1,200 样本; 64-D embeddings; 26 targets; 12 active dimensions; noise=0.3
重复	20 个独立 dataset seeds (0–19)
随机留出	75% train / 25% test; 同一 seed 下模型共享完全相同划分
空间留出	4° 矩形 block; GroupShuffleSplit; 25% blocks 作为测试
基线	RandomForestRegressor; 50 trees; max_features=1.0; bootstrap=True
完整改进	ExtraTreesRegressor; 100 trees; max_features=0.7; bootstrap=False
主终点	每个 seed 对 26 个 target test R ² 的宏平均
统计	配对 t; Wilcoxon; 10,000 次 seed-cluster bootstrap 95% CI; Cohen dz
多重比较	26 个变量的配对 t 检验使用 Benjamini–Hochberg FDR
鲁棒性	n∈{500,1200} × noise∈{0.3,0.9}; 每格 8 seeds

主分析单位是“数据种子”，而不是把 26 个高度相关的目标变量错误地当作 520 个独立重复。每次 bootstrap 重采样 20 个 seed 级配对差值，从而保持每个 seed 内 26 targets 的相关结构。

5. 主实验结果

表 4 主终点与空间稳健性结果

终点	RF 基线	ExtraTrees	配对 Δ	95% CI	p (paired t)
随机留出 macro R ²	0.4909	0.5158	+0.0249	[0.0223, 0.0275]	2.06e-13
空间分块 macro R ²	0.4406	0.4685	+0.0279	[0.0222, 0.0343]	4.62e-08

随机留出相对提升为 5.1%，Cohen dz=4.03；20/20 seeds 的差值均为正。Wilcoxon 检验同样显著（p=1.91e-06），说明结论不依赖正态差值假设。空间分块相对提升为 6.3%，20/20 seeds 同样获益。




图1 20 个独立数据种子的配对宏平均测试 R^2 。所有点均位于等值线之上。




图2 26 个环境变量的配对 ΔR^2 与 seed-cluster bootstrap 95% CI。青色表示 BH 校正后 $q < 0.05$ ；本实验 26/26 全部显著。

6. 消融研究与机制分析

表5 ExtraTrees 组件消融

模型	Macro R ²	vs RF ΔR^2	95% paired CI	Seed win rate
RF 50 trees	0.4909	+0.0000	[+0.0000, +0.0000]	0%
ET 50 trees, all features	0.5082	+0.0173	[+0.0152, +0.0195]	100%
ET 100 trees, all features	0.5141	+0.0232	[+0.0211, +0.0254]	100%
ET 50 trees, 0.7 features	0.5094	+0.0185	[+0.0157, +0.0213]	100%
ET 100 trees, 0.7 features	0.5158	+0.0249	[+0.0223, +0.0275]	100%

仅把标准 RF 换成相同 50 棵树的 ExtraTrees 即贡献 +0.0173 R^2 ，说明随机阈值是主要收益来源。增加到 100 棵树将增益扩大到 +0.0232；单独进行 70% 特征子采样得到 +0.0185。二者组合达到 +0.0249，表明更多树主要用于稳定额外随机性，而特征子采样提供较小但一致的补充收益。




图3 各消融模型相对RF 的配对宏平均 ΔR^2 ；误差线为 95% bootstrap CI。

7. 鲁棒性、效率与可解释性权衡

表6 样本量与噪声压力测试 (每格 8 seeds)

n	Noise	RF	ET	ΔR^2	95% CI
500	0.3	0.4379	0.4655	+0.0275	[0.0222, 0.0333]
500	0.9	0.4298	0.4537	+0.0239	[0.0188, 0.0290]
1200	0.3	0.4858	0.5114	+0.0256	[0.0208, 0.0303]
1200	0.9	0.4749	0.5016	+0.0267	[0.0237, 0.0295]

四个压力条件的平均增益均为正且置信区间不跨 0 (+0.0239 至 +0.0275)。这说明收益不局限于主实验的单一样本量或噪声水平；尤其在 n=500 的小样本条件下仍保持提升。




图4 样本量×嵌入噪声鲁棒性网格；每格数值为ExtraTrees-RF的配对宏平均 ΔR^2 。

计算成本方面，完整模型虽然把树数从 50 增至 100，但中位 fit+evaluation 时间从 3.19s 降至 2.71s。ExtraTrees 不搜索每个特征的最优切分点，因此在本机上抵消了树数增加的开销。该时间结论依赖硬件、线程调度与 scikit-learn 版本，应作为同机相对比较而非普适吞吐量保证。




图5 五个模型的准确率—计算时间关系。完整 ExtraTrees 同时位于更高 R^2 与更短时间区域。

7.1 维度恢复是否退化

表7 支持集恢复对比

指标	RF	ET	配对 Δ	paired t p	解释
Support mAP	0.8827	0.8901	+0.0074	0.101	小幅上升，但不显著
Recall@true-k	0.7806	0.7971	+0.0164	0.065	探索性改善，t 检验未过 0.05
Mapping Recall@3	0.9625	0.9625	-0.0000	1.000	完全保持




图6 维度支持集恢复。完整 ExtraTrees 未牺牲基线的 Top-3 映射召回。

这里的支持集指标使用两种模型各自的树内 `feature_importances_`，用于低成本二级检查；它不是论文在 100,000 样本上计算的置换重要性，因此不能替代真实数据上的 `permutation-importance` 复核。Support mAP 的 95% CI 跨 0，最稳妥结论是“未发现系统性退化”，而不是“可解释性显著提升”。

8. 学术讨论

8.1 对论文限制的回应

论文已表明多任务 Transformer 在 26 个变量上全面优于 RF，但其训练使用 5M 样本、60 epochs 和 32GB GPU。本研究提供了介于 RF 与 Transformer 之间的低成本改进：保持树模型的直接特征重要性和低工程复杂度，在 CPU 合成复现中取得约 5.1% 的宏平均 R^2 相对增益。它不是对 Transformer 的替代性胜出，而是资源受限场景的合理 Pareto 改进。

8.2 为什么城市变量收益最大

逐变量结果中 population_density 与 impervious_surface 的平均增益均约 +0.067。合成生成器用局部化的二维空间核构造城市变量，其响应面比温度等平滑梯度更非线性。随机阈值提供了更多样的局部划分，因而比高度相关的最优切分 RF 更容易通过集成逼近此类结构。这一机制解释与数据生成过程一致，但仍需真实城市指标验证。

8.3 统计意义与实际意义

极小的 p 值来自高度一致的 seed 级配对差值，而不是人为扩大样本量。主增益 +0.0249 R² 的绝对幅度中等，但 20/20 seeds、空间留出增益与四格压力测试共同提高了证据可信度。对于已接近 1.0 的高信号变量，绝对提升自然较小；对局部非线性或较弱编码变量，提升更大。

9. 威胁效度与潜在取舍

表8 内部与外部效度威胁

威胁	影响	缓解与后续
合成数据	缺少真实 AlphaEarth 光谱/时间/传感器结构	在真实 embedding + 26 ancillary variables 上原样复跑
样本规模	1,200 远小于论文 700k RF 子样本	增加 n 并记录收益曲线；验证 ExtraTrees 在大样本是否仍快
空间块方案	4° GroupShuffleSplit 与论文 2° 五折不完全相同	真实数据采用论文 2° GroupKFold，报告逐变量 gap
重要性类型	二级支持检查使用 impurity importance	最终 dimension dictionary 使用 permutation importance 与 bootstrap stability
超参数探索	仅比较有限树数与 max_features	嵌套 CV 或预注册更广搜索，防止选择偏差
多目标信息未利用	仍为 26 个独立模型	后续比较 MultiOutput ExtraTrees 与轻量多任务网络
运行时间外部性	并行库与硬件可能改变比例	报告 CPU/版本并在目标环境重复 benchmark

潜在取舍包括：ExtraTrees 的随机阈值可能在极平滑、低噪声、可外推问题上增加偏差；树模型本身不能像线性模型那样向训练范围之外外推；双倍树数可能提高模型存储和推理内存，即使本机

训练时间更短。本实验未序列化模型，因此没有量化磁盘和峰值内存，报告不作无证据的成本结论。

10. 结论与建议

结论 在本复现的合成任务上，100-tree ExtraTrees (max_features=0.7) 相对 50-tree RF 具有统计显著、空间稳健且计算更快的预测性能提升；Top-3 维度映射恢复不变。H1、H2 获支持，H3 未见反证。

建议将完整 ExtraTrees 配置作为更新代码库的默认“轻量改进候选”，但在真实 AlphaEarth 数据上完成以下门槛后再升级为论文级结论：（1）使用论文同源 26 变量和 2° GroupKFold；（2）至少 5 个数据/模型种子；（3）统一 permutation importance 子集；（4）同时报告 R²、空间 gap、重要性稳定性、训练/推理成本；（5）与原 RF 和轻量 Transformer/多输出树共同比较。

附录 A：一键复现与产物

表 A1 复现实验命令与审计产物

命令/文件	用途
python -m pytest tests/test_improvement.py	运行 3 个核心回归测试
python experiments/run_improvement_experiment.py	完整 20-seed 实验、统计与图表
results/improvement/aggregate_metrics.csv	seed/model/condition 级聚合结果
results/improvement/per_variable_metrics.csv	逐变量原始测试 R ²
results/improvement/experiment_summary.json	配置、软件元数据、CI、检验、消融、鲁棒性
results/improvement/figures/	6 张报告级 PNG
IMPROVEMENT_NOTES.md	修改说明与复现入口

完整代码修改位于独立 Git 分支中；新增模块和生成器变更均带显式标记。实验结果 CSV/JSON 已纳入仓库，因此读者可以先审计数字，再选择是否重新运行约 9 分钟的完整实验。

参考文献

- [1] Rahman, M. (2026). Physically Interpretable AlphaEarth Foundation Model Embeddings Enable LLM-Based Land Surface Intelligence. arXiv:2602.10354. <https://arxiv.org/abs/2602.10354>
- [2] Breiman, L. (2001). Random Forests. Machine Learning, 45, 5–32. <https://doi.org/10.1023/A:1010933404324>
- [3] Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely Randomized Trees. Machine Learning, 63, 3–42. <https://doi.org/10.1007/s10994-006-6226-1>
- [4] scikit-learn developers. Ensemble methods: Random forests and extremely randomized trees. <https://scikit-learn.org/stable/modules/ensemble.html>
- [5] chabingcha. alphaeearth-reproduction. GitHub repository. <https://github.com/chabingcha/alphaeearth-reproduction>